

基于大数据和 AI 的高考志愿填报多目标推荐模型与交互式原型系统

——以广东样例数据接入与 Streamlit 原型实现为例

版本：v3.2.4_paper_final

摘要

高考志愿填报是一个同时涉及分数位次、院校录取、专业适配、城市机会和风险控制的多目标决策问题。本文围绕 Project 5 对“可计算、可解释、可交付”的要求，构建了一套高考志愿填报多目标推荐模型，并在 Python 中实现了可交互的 Streamlit 原型系统。系统以综合效用函数为总框架，包含分数一位次等效换算、院校/专业录取概率预测、冲稳保志愿组合优化、志愿填报风险评估和专业就业前景度评价五个核心模型。

当前版本支持模拟数据 Demo、广东样例数据和真实数据模式占位三种数据模式；支持 3+3 六选三和 3+1+2 首选物理/历史加再选四选二的选科输入；支持院校名称、院校代码、专业组代码、专业组名称和专业名称的完整展示；并提供 JSON、Markdown 与 CSV 导出。广东样例数据用于展示真实数据接入流程，包含一分一段表、投档线、招生计划、专业与城市等样例字段，但仍需在真实上线前补齐官方 source_trace、跨省数据和人工复核。

在工程实现中，本文重点修复了三个影响业务可用性的关键问题：其一，修正一分一段表累计人数递增时等效分插值方向错误的问题，避免出现 620 分、11500 位次被换算为 100 分左右的异常结果；其二，修复 UI 选科组合未正确传入 profile 导致候选志愿被全部过滤的问题；其三，修复志愿表只显示专业、不显示院校的问题。系统测试结果显示：当前 58 个 pytest 测试通过，main.py --test 通过，docs/api_spec.json 可正常解析，Streamlit 页面能够完成输入、推荐、解释和导出流程。

关键词：高考志愿填报；多目标优化；分数位次换算；录取概率预测；冲稳保垫；风险评估；Streamlit

目录

- 一、问题重述
- 二、问题分析
- 三、数据来源、真实数据接入与数据字典
- 四、数据清洗与预处理
- 五、模型假设
- 六、符号说明
- 七、总模型：多目标志愿推荐函数
- 八、模型一：分数一位次等效换算模型
- 九、模型二：院校/专业录取概率预测模型
- 十、模型三：冲稳保志愿组合优化模型
- 十一、模型四：志愿填报风险评估模型
- 十二、模型五：专业就业景气度评价模型
- 十三、广东样例数据接入与院校专业组适配
- 十四、交互式系统设计与 Streamlit 页面实现
- 十五、统一接口输出标准
- 十六、模型评价与测试案例
- 十七、模型优缺点分析
- 十八、实施路线与真实上线要求
- 十九、结论
- 参考文献与附录

一、问题重述

高考志愿填报的核心并不是简单地按分数查表，而是在有限时间内根据考生分数、全省位次、选科组合、家庭约束和职业偏好，形成一张结构合理、风险可控且便于解释的志愿表。Project 5 明确要求模型必须服务业务，不是为了写漂亮公式，而是让家长、咨询师和产品系统都能使用。因此，本课程将高考志愿填报拆解为一组可计算、可解释、可交付的模型模块。

本文需要解决的问题包括：第一，如何将不同年份的分数转换到可比较的位次或等效分口径；第二，如何根据历史投档线、招生计划与考生位次估计录取概率；第三，如何在硬约束下形成冲、稳、保、垫梯度合理的志愿组合；第四，如何识别滑档、退档、调剂、专业冷门、就业和地域等风险；第五，如何将专业就业和城市机会纳入综合评价；第六，如何将模型结果转化为可交互的系统界面和可交付的报告。

当前实现版本以 v3.2.2_school_display_fix 代码为基础，同时在本文中按最终论文口径整理。系统支持模拟数据 Demo 与广东样例数据。广东样例数据只作为真实数据接入流程的展示，不等同于完整上线数据库。真实上线前仍需接入各省教育考试院、高校招生网和就业质量报告等官方公开数据，并完成字段追溯、人工抽检和分层回测。

二、问题分析

2.1 决策链条分析

高考志愿填报的决策链条可以概括为“分数位次定位—候选池生成—概率预测—多目标排序—风险扫描—解释交付”。其中，分数位次定位决定候选池是否合理；概率预测决定冲稳保垫分层；多目标排序决定志愿顺序；风险扫描决定是否需要人工复核；解释交付决定系统能否被家长和咨询师理解。

2.2 模型与业务的对应关系

表 1 业务问题与模型对应关系

业务问题	对应模型	主要输出
跨年度分数不可比	分数—位次等效换算	equivalent_score, percentile, confidence_level
目标院校录取可能性	录取概率预测	admit_probability, probability_interval, recommendation_tier
整张志愿表如何组合	志愿组合优化	volunteer_list, rush/stable/safe/bottom count
滑档退档和调剂风险	风险评估	six risk scores, review_required
专业毕业后价值	就业景气度评价	career_score, red/yellow/green label
页面与交付	Streamlit 原型与统一 JSON	解释报告、下载文件、接口结果

由表 1 可见，本文并不将模型孤立地作为公式，而是将每个模型放入业务流程：输入来自数据表和用户画像，输出进入下一步模型和最终界面。

三、数据来源、真实数据接入与数据字典

3.1 数据模式

系统当前提供三种数据模式：模拟数据 Demo、广东样例数据、真实数据模式占位。模拟数据 Demo 用于快速演示全流程；广东样例数据用于展示公开数据接入、字段适配和院校专业组展示流程；真实数据模式为后续接入各省官方数据预留接口。

表 2 当前数据模式说明

数据模式	用途	边界说明
模拟数据 Demo	快速验证流程和 UI 展示	数据由程序生成，不代表真实院校和真实录取情况
广东样例数据	展示一分一段、投档线、招生计划等表的接入方式	包含部分公开数据和演示补充字段，不等于完整真实填报数据库
真实数据模式	后续接入官方公开数据	当前为占位，未配置完整 data/processed 时应提示用户

3.2 七类数据表

表 3 数据表、用途与模型入口

数据表	主要字段	进入模型
segment_table	score, segment_count, cumulative_count, rank, percentile	模型一等效换算
school_admission_line	school_code, school_name, major_group_code, min_admission_score, min_admission_rank	模型二候选池和概率估计
major_admission	major_code, major_name, min_admission_rank, avg_score	模型二和专业层级解释
admission_plan	plan_count, tuition, subject_requirement, physical_limit	模型三硬约束过滤
major_employment	employment_rate, salary, job_count, postgraduate_rate	模型五就业评价
city_data	city, gdp, related_job_count, average_salary, living_cost	总模型城市分
candidate_profile	score, rank, selected_subjects, risk_preference, excluded_majors	全部模型输入

3.3 source_trace 追溯字段

真实上线时每条记录都应包含 source_url、source_name、crawl_time、data_version、source_type 五个追溯字段。当前广东样例数据仍存在部分 source_trace 不完整的情况，因此页面和论文均将其定位为“广东样例数据”，而不是完整上线数据。

表 4 source_trace 字段

字段	含义
source_url	官方网页、PDF、Excel 或本地文件路径
source_name	数据源名称，如广东省教育考试院或高校招生网
crawl_time	采集或导入时间
data_version	数据版本号
source_type	html/pdf/excel/csv/manual/simulated/api/dynamic

四、数据清洗与预处理

数据清洗的目标是将不同来源、不同命名方式、不同数据类型的表格统一为模型可使用的标准字段。系统的 cleaner.py 提供字段标准化、年份与省份规范化、学校和专业代码格式统一、累计人数单调性检查、位次区间修正、跨表一致性校验和清洗日志生成等功能。

广东样例数据中，投档线表和招生计划表可能分别使用院校代码、专业组代码、最低投档分、最低排位等字段。系统读取后统一映射为 school_code、school_name、major_group_code、major_group_name、min_admission_score、min_admission_rank 等字段。对于缺失的专业组名称或专业名称，页面展示时使用空值兜底或专业组层级说明，避免出现只显示专业名而不显示院校的情况。

表 5 清洗规则示例

问题	处理方式
分数、位次为字符串	转为数值，非法值置空并记录 warning
同一分数多行	按 score 聚合，保留最大 cumulative_count
专业组字段命名不一致	院校专业组、专业组代码统一映射为 major_group_code
选科要求缺失	不直接删除候选，标记需人工复核
source_trace 不完整	标记 source_trace_status=incomplete

五、模型假设

- 1. 在同一省份、同一科类或选科组合内，考生位次比分数更稳定，可作为跨年比较的主要依据。
- 2. 历史投档线和最低位次能够反映院校专业组录取难度，但仍受招生计划、热度和政策变化影响。

- 3. 家庭预算、地域偏好、排斥专业等约束可分为硬约束和软约束；硬约束不得违反，软约束可在候选过少时提示用户放宽。
- 4. 专业就业数据存在口径差异，因此就业评分仅作为辅助决策，不承诺未来就业和薪资。
- 5. 当前广东样例数据用于展示真实数据接入流程，真实上线前必须进行官方数据补齐、source_trace 校验和咨询师人工复核。

六、符号说明

表 6 主要符号说明

符号	含义
P_admit	录取概率
M_fit	专业匹配度
E_career	就业价值分
C_city	城市价值分
R_family	家庭资源匹配度
Risk	综合风险
x_i	第 i 个候选志愿是否被选入志愿表
rank	考生全省位次，数值越小代表排名越靠前
N	对应科类总人数
q	分位点，q=rank/N

七、总模型：多目标志愿推荐函数

总模型将录取概率、专业匹配、就业价值、城市价值、家庭匹配和综合风险统一到一个效用函数中。对于第 i 个候选志愿，效用函数定义为：

$$U_i = \alpha P_{admit_i} + \beta M_{fit_i} + \gamma E_{career_i} + \delta C_{city_i} + \eta R_{family_i} - \lambda Risk_i$$

其中 α、β、γ、δ、η、λ 为权重系数。系统提供 aggressive、balanced、conservative 三种风险偏好。激进型更重视专业匹配和上限，保守型更重视录取概率和家庭风险承受能力，均衡型在录取概率、专业匹配和就业价值之间折中。

表 7 三种风险偏好权重示意

方案	录取概率	专业匹配	就业价值	城市价值	家庭匹配	风险惩罚
激进型	较低	较高	较高	中等	中等	中等
均衡型	中等	中等	中等	中等	中等	中等
保守型	较高	中等	较低	中等	较高	较高

Five-Layer System Architecture




图 1 系统总体架构示意

八、模型一：分数一位次等效换算模型

8.1 业务问题

不同年份的试卷难度、考生人数和招生计划不同，直接比较分数容易误判。模型一通过一分一段表把考生位次转换为分位点，再映射到目标年份的等效分，解决“今年 620 分与去年多少分相当”的问题。

8.2 数学模型

$$q = rank / N$$

其中 q 为考生所在分位点，N 为该省该科类总人数。给定目标年份段表，将 cumulative_count / N 作为单调递增的分位点序列，再用线性插值求得对应分数。

$$S_{target}(q) = S_j + (q - q_j) / (q_{j+1} - q_j) \cdot (S_{j+1} - S_j)$$

当前版本修复了等效分模型中的关键问题：一分一段表按分数从高到低排列时，cumulative_count 通常递增，因此总人数必须取 cumulative_count.max()；分位点序列是递增序列，插值边界为 q 小于最高分分位点返回最高分，q 大于最低分分位点返回最低分。该修复避免了 620 分、11500 位次被错误映射到 100 分附近的异常情况。

表 8 等效分模型输出字段

字段	说明
equivalent_score	多年份加权后的等效分
equivalent_score_interval	考虑年份波动后的区间
equivalent_rank	等效位次
percentile	考生分位点
confidence_level	置信等级
fallback_rule	缺失或异常数据时的回退规则
review_required	是否需要人工复核




图 2 分数—位次曲线示例

九、模型二：院校/专业录取概率预测模型

模型二根据历史投档位次、招生计划变化、专业热度和考生位次估计录取概率。系统采用 Logistic 回归、XGBoost、贝叶斯修正和蒙特卡洛模拟四类结果融合，并对小样本专业扩大概率区间。

$$p_{fuse} = w_1 p_{LR} + w_2 p_{XGB} + w_3 p_{Bayes} + w_4 p_{MC}$$

录取概率映射为冲、稳、保、垫四层。统一规则为： $p < 0.20$ 为高风险冲刺，仍计入冲但必须人工复核； $0.20 \leq p < 0.45$ 为冲； $0.45 \leq p < 0.70$ 为稳； $0.70 \leq p < 0.88$ 为保； $p \geq 0.88$ 为垫。概率上限不输出 100%，最高按 0.99 处理。

表 9 录取概率分层规则

概率区间	层级	业务含义
$p < 0.20$	高风险冲刺	可作为极少量上限尝试，需人工复核
$0.20 \leq p < 0.45$	冲	存在录取机会，但不确定性较大
$0.45 \leq p < 0.70$	稳	录取机会较为均衡
$0.70 \leq p < 0.88$	保	相对稳妥，但仍需看招生计划
$p \geq 0.88$	垫	作为兜底层，不承诺一定录取




图 3 录取概率分布示例

十、模型三：冲稳保志愿组合优化模型

模型三的任务不是推荐单个学校，而是在志愿数量约束下生成一整张梯度合理的志愿表。优化目标是在满足硬约束的前提下最大化综合效用。

$$\max \sum x_i U_i$$

硬约束包括选科要求、明确排斥专业、学费预算、身体限制、单科限制和不接受调剂时的高调剂风险过滤。软约束包括偏好城市、就业优先、升学优先等。若软约束过严导致候选过少，系统应提示用户放宽，而不是静默返回空结果。

表 10 志愿优化输出字段

字段	说明
volunteer_list	最终志愿列表
rush_count/stable_count/safe_count/bottom_count	冲稳保垫数量
overall_score	方案综合得分
overall_risk_level	整体风险等级

adjustment_suggestion	修改建议
editable	咨询师是否可编辑




图 4 冲稳保垫结构图

十一、模型四：志愿填报风险评估模型

风险评估模型从滑档、退档、调剂、专业冷门、就业、地域六个维度计算风险分数，并扫描冲太多、保底不足、排斥专业被纳入、小样本专业过度乐观等典型问题。

表 11 六类风险定义

风险类型	触发示例
滑档风险	冲志愿过多、保底不足、整体录取概率低
退档风险	体检、单科成绩、专业限制不满足
调剂风险	不接受调剂但专业组内部差异大
专业冷门风险	专业就业或热度长期偏低
就业风险	薪资、岗位和稳定性指标偏弱
地域风险	城市偏好与候选院校所在地不匹配




图 5 六类风险热力图示例

十二、模型五：专业就业景气度评价模型

专业就业景气度评价模型采用 AHP、熵权法、TOPSIS 和聚类分析，对专业就业率、薪资水平、岗位数量、岗位增长、稳定性、考研价值、考公适配度等指标进行综合评价。社媒舆情仅作为辅助预警，不作为核心就业评分依据。

$$career_score = TOPSIS(AHP_weight \times Entropy_weight, normalized_indicators)$$

表 12 就业评价指标

指标	含义
salary_score	薪资水平与薪资口径
stability_score	岗位稳定性与行业周期性
growth_score	岗位增长与行业成长
postgraduate_value_score	读研后就业价值
civil_service_score	考公考编适配度
red_yellow_green_label	红黄绿风险标签




图 6 专业就业多维雷达图示例

十三、广东样例数据接入与院校专业组适配

广东新高考志愿以“院校专业组”为重要填报单位。系统在广东样例数据模式中保留 school_name、school_code、major_group_code、major_group_name、major_code、major_name 等字段。当前版本已修复志愿表只显示专业名、不显示学校名的问题，页面中每条志愿均展示院校名称、院校代码、专业组代码和专业名称，使用户能够明确知道“报哪所学校、哪个专业组、哪个专业”。

对于专业级数据缺失或专业组内专业需要进一步查验的情况，系统不应简单删除候选，而应保留院校专业组层级候选，并标记 review_required=True。页面中也应提示“该候选基于院校专业组投档线生成，具体专业、选科要求、学费和身体限制需查官方招生计划复核”。

表 13 广东样例数据文件概况

类别	样例规模/说明
----	---------

一分一段表	覆盖多个年份和物理类、历史类口径
投档线	2023-2024 年本科投档线样例
招生计划	2024、2026 年样例字段，用于展示选科要求和计划数
专业数据	专业录取与就业样例字段
城市数据	广东 20 市城市产业和成本样例
学校信息	约 900 所院校基础信息样例

十四、交互式系统设计与 Streamlit 页面实现

系统提供 Streamlit 交互页面，用户可以在左侧栏输入数据模式、省份、分数、位次、年份、新高考选科、风险偏好、家庭预算、偏好城市和排斥专业。页面支持“加载演示案例”按钮，便于快速演示。

选科输入分为两种模式：3+3 模式下从物理、化学、生物、历史、地理、政治六门中选择三门；3+1+2 模式下先在物理和历史中选择一门，再从化学、生物、地理、政治中选择两门。系统内部生成 exam_mode、first_subject、selected_subjects、subject_combo 和 subject_type，其中 subject_type 作为模型兼容口径，取值为物理类、历史类或综合类。

页面分为推荐总览、志愿表、风险分析、专业就业、解释报告和数据说明等模块。志愿表支持展示院校名称、院校代码、专业组代码、专业名称、录取概率、概率区间、冲稳保垫、就业分、城市分、综合效用和是否需要复核。概率区间显示时会先排序 lower 和 upper，再进行 0-0.99 边界裁剪，避免出现 100%-99% 之类的反向区间。

表 14 Streamlit 页面模块

模块	功能
侧边栏输入	数据模式、考生信息、选科、风险偏好、城市和排斥专业
推荐总览	等效分、综合风险、需复核数量、冲稳保垫统计
志愿表	学校、专业组、专业、概率、风险、解释和修改建议
风险分析	六类风险和人工复核清单
专业就业	就业评分和红黄绿标签
解释报告	家长端说明、咨询师提示和下载导出
数据说明	模拟数据、广东样例数据和真实数据边界

十五、统一接口输出标准

pipeline.py 统一输出 meta、candidate、recommendation_plan 三个顶层字段。recommendation_plan 中包含 volunteers、statistics 和 risk_assessment。docs/api_spec.json 对输入输出、错误码、字段来源和示例响应进行了结构化说明。

表 15 volunteers 单项字段

字段	说明
school_code / school_name	院校代码与院校名称
major_group_code / major_group_name	专业组代码与名称
major_code / major_name	专业代码与专业名称
admit_probability / probability_interval	录取概率和概率区间
recommendation_tier	冲、稳、保、垫
career_score / city_score / overall_utility	就业分、城市分和综合效用
explanation / modification_suggestion	推荐理由和修改建议
review_required	是否需要咨询师复核
source_trace	数据来源追溯信息

十六、模型评价与测试案例

当前项目包含 7 个测试文件，共 58 个 pytest 测试。测试覆盖等效分输出字段、概率范围、冲稳保垫映射、小样本复核、就业分范围、排斥专业过滤、预算约束、地域约束、六类风险、pipeline 输出结构和禁止表述检查等内容。

表 16 测试与验证结果

验证项	结果
pytest tests/ -q	58 passed
main.py --test	通过
docs/api_spec.json	JSON valid
Streamlit 页面	可输入、生成方案、展示志愿表并导出
广东样例数据	物理类和历史类常见组合可生成非空方案
等效分修复	620 分 / 11500 位次不再映射到 100 分附近
学校名展示	志愿表显示院校名称、代码、专业组和专业

评价指标方面，模型一关注 MAE、RMSE、置信区间覆盖率和异常年份识别；模型二关注 AUC、Brier Score、校准曲线和小样本复核率；模型三关注约束满足率、志愿结构达标率和咨询师修改率；模型四关注六类风险识别和高风险复核触发；模型五关注专业排序稳定性、红黄绿标签一致性和就业数据完整率。

十七、模型优缺点分析

17.1 优点

6. 模型体系完整，覆盖从位次定位到志愿组合和解释交付的全流程。
7. 输入输出字段清晰，能够接入 Web 页面和后续小程序/咨询后台。
8. 对 3+3 和 3+1+2 选科模式均有支持，符合新高考场景。
9. 志愿表展示包含学校、专业组和专业，避免只显示专业名造成误解。

10. 对模拟数据、广东样例数据和真实数据模式进行了明确区分，避免夸大数据能力。

17.2 不足

- 11. 广东样例数据仍非完整上线数据库，部分 source_trace 和专业级字段需要补齐。
- 12. 录取概率模型中的机器学习组件仍需要真实历史录取标注数据进行分层训练和校准。
- 13. 就业评价依赖样例就业数据，真实上线需接入高校就业质量报告和招聘岗位数据。
- 14. 当前推荐仍需咨询师复核，尤其是专业组层级候选、小样本专业和高风险冲刺志愿。

十八、实施路线与真实上线要求

表 17 三阶段实施路线

阶段	主要任务	交付物
第 1 阶段：基础模型	位次换算、录取概率、冲稳保初版	候选志愿表、概率分层、规则库
第 2 阶段：增强模型	就业景气、城市匹配、风险评估、解释模板	专业画像、风险标签、解释报告
第 3 阶段：系统化落地	真实数据接入、API 联调、咨询师内测	后台接口、真实回测报告、案例库

真实上线前，必须补齐各省官方公开数据源、source_trace、字段映射、分层训练、留年回测、概率校准、咨询师人工复核和数据合规检查。系统不得输出“保证录取”“一定能上”等绝对化表述，也不得将样例数据结果直接作为真实填报依据。

十九、结论

本文围绕高考志愿填报的真实业务需求，构建并实现了一套多目标推荐模型与交互式原型系统。系统以综合效用函数为总框架，融合分数一位次等效换算、录取概率预测、志愿组合优化、风险评估和就业景气度评价五个核心模型，并提供统一 JSON 接口、测试案例、业务解释模板和 Streamlit 页面。

当前版本已经完成若干影响可用性的关键修复：等效分插值逻辑修复、选科组合向 profile 传递修复、广东历史类空方案修复、学校名称和专业组展示修复、概率区间显示修复。系统能够作为数学建模论文和交互式原型 Demo 提交，但仍不能作为真实上线系统。未来需补齐全国官方数据、source_trace、真实回测和咨询师复核流程，才能进入实际志愿填报服务场景。

参考文献

[1] Project 5 高考志愿建模课题. 基于大数据和 AI 的高考志愿填报系统数学建模子项目拆解与交付要求, 2026.

[2] 广东省教育考试院. 普通高考一分一段表与本科批次投档线公开数据.

[3] Chen T., Guestrin C. XGBoost: A scalable tree boosting system. KDD, 2016.

[4] Saaty T. L. The Analytic Hierarchy Process. McGraw-Hill, 1980.

[5] Hwang C. L., Yoon K. Multiple Attribute Decision Making: Methods and Applications. Springer, 1981.

[6] Breiman L. Random forests. Machine Learning, 2001.

[7] Bishop C. M. Pattern Recognition and Machine Learning. Springer, 2006.

[8] 教育部、各省教育考试院及高校本科招生网公开招生章程与投档信息.

附录 A 数据字段字典

核心字段包括 candidate_id、province、year、exam_mode、selected_subjects、subject_type、score、rank、school_code、school_name、major_group_code、major_group_name、major_code、major_name、admit_probability、probability_interval、recommendation_tier、career_score、city_score、overall_utility、risk_level、review_required 和 source_trace。

附录 B 核心算法伪代码

输入考生画像后，系统先读取对应数据模式，完成一分一段表等效换算；再根据投档线和计划生成候选池；随后计算录取概率、就业分、城市分和风险分；最后按多目标效用函数排序并生成冲稳保垫志愿表。

附录 C 统一 JSON 输出示例

JSON 顶层包含 meta、candidate、recommendation_plan。candidate 记录分数、位次、选科、等效分和 source_trace；recommendation_plan 包含 volunteers、statistics 和 risk_assessment。

附录 D Streamlit 页面运行说明

安装依赖后运行：streamlit run streamlit_app.py。页面打开后可点击“加载演示案例”，或手动选择数据模式、省份、分数、位次、年份和选科组合，再点击生成志愿方案。

附录 E 测试案例与验证结果

测试覆盖冲、稳、保、垫、高分冲名校、中分均衡、低分保底、不接受调剂、排斥专业、预算受限、地域约束、异常年份、小样本专业和就业高风险专业等场景。